Departamento de Engenharia Informática e de Sistemas

BIG DATA

Mestrado em Engenharia Informática

Exame Época Normal — 21/JUN/2021

Duração: 1 h 30m (+ 30 min de tolerância)

Atenção:

- O enunciado procura ser tão completo e claro quanto possível. Porém, se lhe parecer que há alguma ambiguidade, esclareça a sua interpretação e responda em conformidade.
- As respostas devem ser objetivas e completas.

1. a) **(3%)** Distinga os conceitos de "scale-up" e "scale-out".
b) **(7%)** Numa empresa que tenha grandes quantidades de dados que necessitem de ser armazenados e processados, qual será a melhor opção, usar "scale-up" ou "scale-out"? Porquê? Justifique convenientemente.

2. Uma das principais características dos sistemas NoSQL é sua capacidade para lidar com Big Data.
a) **(2%)** O termo Big Data é na maior parte das vezes definido por 5 V's. Indique cada um destes V's.
b) **(7%)** Explique o significado de cada um destes V´s e a sua importância em sistemas NoSQL.

3. a) **(1%)** Em quantos tipos são usualmente classificados os sistemas NoSQL?
b) **(8%)** Descreva sucintamente cada um dos tipos de sistemas NoSQL.
c) **(5%)** Indique três exemplos de bases de dados NoSQL para cada um dos tipos.

Resolva as perguntas seguintes noutra folha de prova

4. **(5%)** Indique as principais funcionalidades do HDFS?

5. **(7%)** Indique as principais vantagens do paradigma MapReduce?

6. **(10%)** Comente a afirmação: "*Em HDFS, os ficheiros são divididos em chunks de tamanho variável de acordo com as características físicas de cada datanode, de modo a garantir uma distribuição equilibrada entre nós.*

7. **(10%)** Comente a afirmação: "*Em termos de execução, as pesquisas SQL executadas utilizando o Hive são mais rápidas do que executadas utilizando o Hadoop.*"

8. **(10%)** Em Hive, as tabelas podem ser criadas em diferentes *storage formats*. Indique três, e distinga-os.

9. **(10%)** Enumere as principais vantagens do Spark em relação ao Hadoop?

10. **(5%)** Em Spark existe o conceito de RDD. Defina RDD.

11. **(10%)** A tolerância a falhas é um aspeto relevante tanto no Hadoop como no Spark. Distinga o modo como a tolerância a falhas é atingido no Spark e no Hadoop.