Departamento de Engenharia Informática e de Sistemas

BIG DATA

Mestrado em Engenharia Informática

Exame Época Normal 1/JUL/2022

Duração: 1 h 30m (+ 30 min de tolerância)

Atenção:

- O enunciado procura ser tão completo e claro quanto possível. Porém, se lhe parecer que há alguma ambiguidade, esclareça a sua interpretação e responda em conformidade.
- As respostas devem ser objetivas e completas.

1. ***(15%)*** A história das bases de dados está marcada por várias revoluções. Identifique e descreva cada uma das revoluções que estão associadas à evolução das bases de dados. Para cada uma dessas revoluções descreva o(s) marco(s) histórico(s) associado(s) a cada uma delas.

2. ***(15%)*** As aplicações de Big Data abrangem uma vasta gama de domínios incluindo casas, cidades, ambiente, sistemas de energia, comércio retalhista, agricultura, Internet das Coisas. Um dos casos de sucesso diz respeito à logística e transporte nomeadamente para: i) geração e programação de rotas (Route Generation & Scheduling) ii) entrega hiperlocal (Hyper-local Delivery); iii) agregadores de táxi (Hyper-local Delivery). Para cada um destes casos descreva como é que o Big Data pode ser usado e quais as vantagens que produz.

3. Document-oriented é um dos tipos de sistemas NoSQL.
   a) ***(5%)*** Como são armazenados os dados neste tipo de sistema? Descreva sucintamente e forneça uma figura exemplo.
   b) ***(5%)*** Compare a terminologia usada no SGBD Oracle com a do sistema MongoDB, preenchendo a seguinte tabela:

Oracle	MongoDB
Database instance	
Schema	
Table	
Row	
Rowid	
Join	

   c) ***(5%)*** Forneça alguns casos de uso para os sistemas NoSQL do tipo Document-oriented.
   d) ***(5%)*** Supondo que queremos selecionar os pedidos para um único aluno_id=2021007007 numa coleção de Alunos (tabela Alunos).
   O SQL seria: `SELECT * FROM Alunos WHERE aluno_id= 2021007007.`
   Escreva a pesquisa equivalente no sistema MongoDB.

Resolva as perguntas seguintes noutra folha de prova

Resolva as perguntas seguintes noutra folha de prova

4. (10%) Comente a afirmação: "*Num sistema HDFS com um tamanho de chunk de 64MB, quando se faz o upload de um ficheiro de dados com 200MB, este é dividido em 3 ficheiros que posteriormente distribuídos por diferentes namenodes*". Se considerar que está incorreta, reescreva-a.

5. (10%) No contexto do Hadoop, descreva de que modo a escalabilidade do processamento, usando o paradigma map-reduce, está relacionado com a disponibilidade e escalabilidade do HDFS? Justifique.

6. (10%) Em termos de processamento, qual a diferença fundamental quando uma pesquisa SQL é submetida através do Hive ou do SparkSQL? Justifique.

7. (10%) No que concerne ao processamento, indique uma das principais desvantagens do Spark em comparação com Hadoop? Justifique e exemplifique.

8. (10%) O Spark, além do processamento em *batch*, permite também o processamento de dados em *Streaming*. Distinga estes dois tipos de processamento, e indique como o processamento em *Streaming* é implementado no Spark?